

MÔ HÌNH HỌC SÂU KẾT HỢP ESD-NET TRONG PHÂN LOẠI UNG THƯ TRÊN NHỮ ẢNH

Trần Hồ Đạt^{1,2}, Phan Thượng Cang¹, Nguyễn Vĩnh Phong³, Phan Anh Cang^{2✉}

¹Đại học Cần Thơ

²Trường Đại học Sư phạm Kỹ thuật Vĩnh Long

³Bệnh viện Ung bướu Thành phố Cần Thơ

datth@vlute.edu.vn, ptcang@cit.ctu.edu.vn, dr.phong86@gmail.com, cangpa@vlute.edu.vn

TÓM TẮT— Chẩn đoán và điều trị sớm ung thư là một bước quan trọng giúp nâng cao khả năng phục hồi cho bệnh nhân. Các mô hình học sâu trong thời gian qua đã chứng minh hiệu quả trong lĩnh vực y khoa hỗ trợ cho bác sĩ nâng cao năng lực khám chữa bệnh. Dù vậy, kết quả từ từng mô hình đơn lẻ thường thiếu ổn định và dễ bị ảnh hưởng bởi đặc điểm dữ liệu đầu vào gây ảnh hưởng đến quá trình phân loại của các mô hình máy học. Bài báo này đề xuất một mô hình mạng ESD-NET là sự kết hợp của 7 mô hình mạng InceptionV3, Resnet152, Resnet50V2, Densenet121, Densenet201, VGG19, Xception trong phân loại hiệu quả ung thư trên nhữ ảnh. Dữ liệu ban đầu thông qua tiền xử lý để loại bỏ nhiễu, chuẩn hóa và nâng cao chất lượng ảnh trước khi đưa vào huấn luyện. Từ kết quả huấn luyện của các mô hình, chúng tôi thực hiện tổ hợp mô hình học sâu bằng kỹ thuật voting nhằm tận dụng những ưu điểm từ các mô hình riêng lẻ. Phương pháp đề xuất cải thiện hiệu suất phân loại với kỹ thuật Soft voting đạt độ chính xác 95.8% và Hard voting 95.6% trên tập kiểm tra. Kết quả của nghiên cứu góp phần nâng cao độ tin cậy của mô hình đề xuất trong phát hiện sớm ung thư vú.

Từ khóa— nhữ ảnh, ung thư vú, tổ hợp mô hình học sâu.

I. GIỚI THIỆU

Ung thư vú là căn bệnh phổ biến có tỷ lệ mắc và tử vong rất cao. Theo số liệu thống kê của GLOBOCAN[1] trong năm 2022 cả thế giới ước tính có khoảng 19.9 triệu ca mắc và gần 10 triệu ca tử vong do ung thư gây nên. Trong đó, ung thư vú ở phụ nữ là 2.2 triệu ca chiếm 23.8%. Để điều trị có hiệu quả thì phương pháp chụp X-quang tuyến vú (mammography) đóng vai trò quan trọng giúp tầm soát kịp thời các biểu hiện bất thường, kỹ thuật này được sử dụng với mục tiêu sàng lọc thường quy áp dụng cho phụ nữ chẩn đoán khi có dấu hiệu lâm sàng nghi ngờ. Các mô hình học sâu trong thời gian qua mang lại hiệu quả trong lĩnh vực phân loại ảnh y tế, việc tổ hợp nhiều mô hình là hướng tiếp cận giúp nâng cao độ chính xác và giảm sai lệch trong quá trình phân loại. Nhóm nghiên cứu Eroğlu[2] đã đề xuất một hệ thống CNN lai dựa trên hình ảnh siêu âm để chẩn đoán ung thư vú bằng cách trích xuất các đặc điểm từ Alexnet, MobilenetV2 và Resnet50, phương pháp lựa chọn đặc điểm mRMR đã được sử dụng để lựa chọn các đặc điểm tốt nhất của 3 mô hình. Hệ thống này sử dụng các thuật toán học máy hỗ trợ máy vector (SVM) và k-gần nhất (k-NN) làm bộ phân loại. Kết quả nghiên cứu đạt tỷ lệ chính xác 95.6%. Tác giả Adedigba[3] đánh giá nhiều mô hình deep learning (InceptionV3, ResNet50, AlexNet, cùng phương pháp tổ hợp CNN-TV-SVM) trên bộ dữ liệu có kích thước nhỏ, phương pháp tổng quát đề xuất đạt độ chính xác 93.6%, mặc dù hiệu quả của mô hình đề xuất cao nhưng do kích thước tập dữ liệu nhỏ dễ dẫn đến khả năng overfitting cao khi áp dụng trên nhiều tập dữ liệu khác nhau. Tác giả Hashim[4] đề xuất một mô hình tổ hợp Hard voting nhằm phân loại ung thư trên nhữ ảnh. Mô hình này kết hợp ba thuật toán học máy: Decision Tree, Logistic Regression và Support Vector Machine. Trước khi huấn luyện, nhóm tác giả sử dụng Random Oversampling (ROS) để cân bằng và chuẩn hóa bằng Standard Scaler. Mô hình đề xuất đạt kết quả Hard voting 98.25%, với độ chính xác trung bình qua 10 lần kiểm tra chéo là 97.38%. Nghiên cứu này chứng minh rằng phương pháp Hard voting có thể mang lại hiệu suất phân loại cao khi các mô hình thành phần được lựa chọn và kết hợp một cách hợp lý. Hanis[5] và cộng sự thực hiện một phân tích tổng hợp để đánh giá độ chính xác của các mô hình học máy trong phân loại ung thư vú từ ảnh chụp nhữ ảnh kỹ thuật số và tomosynthesis. Nghiên cứu tổng hợp 36 nghiên cứu với 68 mô hình học máy, sử dụng dữ liệu từ các cơ sở dữ liệu công khai như MIAS, DDSM và dữ liệu sơ cấp. Kết quả cho thấy độ chính xác tổng thể cao với AUC là 0.90, độ nhạy 0.83 và độ đặc hiệu 0.84. Các yếu tố ảnh hưởng đến hiệu suất bao gồm quốc gia, nguồn dữ liệu và loại mô hình, trong đó mô hình neural network và dữ liệu từ Mỹ cho kết quả tốt nhất. Tuy nhiên, nghiên cứu cũng chỉ ra một số hạn chế như sự không đồng nhất giữa các nghiên cứu và thiếu dữ liệu tomosynthesis. Những phát hiện này hỗ trợ tiềm năng ứng dụng học máy trong sàng lọc ung thư vú.


Dựa trên kết quả của các nghiên cứu liên quan, chúng tôi đề xuất mô hình ESD-NET nhằm tận dụng ưu điểm của từng mô hình giúp nâng cao độ tin cậy trong bài toán phân loại ung thư trên nhữ ảnh. Mặt khác, quá trình tinh chỉnh các tham số và lựa chọn các mô hình phù hợp được xem xét cẩn thận giúp mô hình đề xuất đạt được hiệu quả cao, đồng thời thực hiện đánh giá phương pháp độ chính xác, độ mất mát và các chỉ số F1-score, Precision, Recall để kiểm chứng độ hiệu quả của mô hình.

II. CÔNG VIỆC LIÊN QUAN

A. Ung thư vú

Ung thư vú hình thành khi các tế bào trong mô vú phát triển bất thường và không kiểm soát. Trong chẩn đoán, tổn thương ở vú thường được phân loại thành hai nhóm chính: lành tính (benign) và ác tính (malignant). Tổn thương lành tính thường không đe dọa tính mạng, phát triển chậm, không xâm lấn với đường ranh giới rõ ràng. Ngược lại với tổn thương lành tính, tổn thương ác tính có đặc điểm phát triển nhanh chóng, có thể xâm nhập vào các mô xung quanh và lan rộng đến các cơ quan khác, đe dọa nghiêm trọng đến tính mạng nếu không được chẩn đoán và điều trị kịp thời. Việc phân biệt chính xác giữa hai loại tổn thương này là yếu tố then chốt trong việc lựa chọn phương pháp điều trị phù

hợp và đạt hiệu quả cao. Nhiều nghiên cứu lâm sàng quy mô lớn đã chứng minh rằng chương trình sàng lọc nhũ ảnh định kỳ có thể giúp giảm từ 20–40% tỷ lệ tử vong do ung thư vú, đồng thời nâng cao khả năng phát hiện bệnh ở giai đoạn đầu. Mặc dù vậy, hiệu quả chẩn đoán vẫn chịu ảnh hưởng bởi chất lượng ảnh và đặc điểm mô vú, đặc biệt ở phụ nữ có mô vú dày. Trong bối cảnh đó, nhu cầu ứng dụng các hệ thống hỗ trợ chẩn đoán bằng trí tuệ nhân tạo ngày càng tăng cao, nhằm giảm thiểu sai sót, tăng tính nhất quán và nâng cao hiệu quả sàng lọc.



Hình 1. Hình ảnh khối u a) lành tính và b) ác tính trên nhũ ảnh

B. Một số mô hình học sâu

InceptionV3[6] là phiên bản nâng cao của kiến trúc Inception, kế thừa từ GoogLeNet nhưng được tối ưu hóa đáng kể về khả năng trích xuất đặc trưng và tính toán. Một trong những cải tiến đáng chú ý là việc áp dụng phép tích chập phân tách (factorized convolutions), thay thế các bộ lọc lớn (ví dụ 5×5 hoặc 7×7) bằng chuỗi các bộ lọc nhỏ hơn (1×n và n×1). Kỹ thuật này tối ưu số lượng tham số mà vẫn bảo toàn việc học các đặc trưng phức tạp. Ngoài ra, InceptionV3 còn sử dụng Batch Normalization để tăng tốc độ hội tụ và giảm hiện tượng overfitting, đồng thời tích hợp phép pooling tối ưu để giảm kích thước không gian. Kiến trúc này phù hợp với các bài toán phân loại đa lớp nhờ khả năng cân bằng giữa độ sâu và hiệu suất. ResNet152[7] và ResNet50V2[8] là hai biến thể tiêu biểu của kiến trúc Residual Network (ResNet), giải quyết vấn đề suy giảm gradient trong mạng cực sâu nhờ cơ chế kết nối tắt (skip connections). ResNet152 với 152 lớp sử dụng các khối residual (Bottleneck) gồm 3 lớp tích chập (1×1, 3×3, 1×1) để giảm chiều dữ liệu trước khi áp dụng phép tích chập 3×3, giúp tiết kiệm bộ nhớ. Kiến trúc ResNet152 phù hợp với tập dữ liệu lớn (như ImageNet) nhờ khả năng học các đặc trưng phân cấp sâu. ResNet50V2 cải tiến từ ResNet gốc bằng cách tái cấu trúc vị trí của Batch Normalization và kết nối tắt. Thay vì áp dụng BN sau mỗi lớp tích chập, ResNet50V2 đặt BN trước hàm kích hoạt (pre-activation), giúp gradient lan truyền ổn định hơn, tăng độ chính xác đồng thời cân bằng giữa độ sâu (50 lớp) và tốc độ huấn luyện, phù hợp cho các tác vụ thời gian thực.


DenseNet121[9] và DenseNet201[10] xây dựng trên nguyên tắc kết nối dày đặc (Dense Connectivity), trong đó mỗi lớp nhận đầu vào từ tất cả các lớp trước đó thông qua phép nối (concatenation). Điều này giúp mạng tái sử dụng đặc trưng hiệu quả, giảm thiểu tham số nhờ chia sẻ thông tin giữa các lớp và giảm vanishing gradient do gradient có nhiều đường truyền ngược. DenseNet121 với 121 lớp phù hợp cho bài toán có sự hạn chế tài nguyên nhưng cần độ chính xác cao, trong khi DenseNet201 (201 lớp) tăng cường khả năng học đặc trưng chi tiết, đặc biệt trong ảnh y tế (ví dụ: phân loại tổn thương da hoặc X-quang). VGG19[11] là kiến trúc cổ điển với 19 lớp, nổi bật nhờ thiết kế đơn giản gồm các khối tích chập 3×3 lặp lại và lớp Max Pooling 2×2. Ưu điểm chính của mạng này là tính đồng nhất bằng việc sử dụng duy nhất bộ lọc 3×3 giúp mạng học các đặc trưng cục bộ theo từng cấp độ (từ cạnh, texture đến đối tượng phức tạp). Mạng VGG19 có độ ổn định cao nhờ số lượng lớn tham số (~144 triệu), nhưng đồng thời đòi hỏi tài nguyên tính toán lớn. VGG19 thường được dùng làm mạng tiền huấn luyện (pre-trained) cho các tác vụ như segmentation hoặc style transfer. Xception[12] (Extreme Inception) mở rộng từ Inception bằng cách thay thế hoàn toàn tích chập thông thường bằng Depthwise Separable Convolution. Thông qua cơ chế này giúp mạng áp dụng bộ lọc cho từng kênh riêng biệt và giảm đáng kể tham số so với tích chập truyền thống mà vẫn giữ được hiệu suất cao trong phân loại.

C. Phương pháp tổ hợp mô hình học sâu

Deep Learning Ensemble[13] hay tổ hợp mô hình học sâu dựa trên sự kết hợp nhiều mô hình học sâu khác nhau giúp nâng cao độ chính xác và ổn định của kết quả phân loại. Bằng cách tận dụng ưu điểm riêng của từng kiến trúc như trích xuất đặc trưng đa dạng của InceptionV3, tính ổn định của ResNet, hay hiệu quả tham số của DenseNet. Việc sử dụng tổ hợp mô hình giúp giảm phương sai (variance), hạn chế overfitting và nâng cao khả năng tổng quát hóa. Hai kỹ thuật phổ biến để kết hợp đầu ra của các mô hình là Hard voting và Soft voting.

1. Hard voting

Hard voting[14] là kỹ thuật tổ hợp mô hình đơn giản và phổ biến, thường được sử dụng trong các bài toán phân loại. Phương pháp này dựa trên cơ chế bỏ phiếu đa số: mỗi mô hình thành phần trong tổ hợp sẽ đưa ra dự đoán nhãn độc lập cho một ảnh đầu là lành tính hoặc ác tính dựa trên đa số phiếu chọn từ các mô hình.



Hình 2. Minh họa cơ chế hoạt động của Hard voting và Soft voting

2. Soft voting

Soft voting[14] là một phương pháp tổ hợp mô hình nâng cao, thường được áp dụng khi các mô hình thành phần có khả năng cho ra xác suất hoặc điểm số dự đoán thay vì chỉ đưa ra nhãn phân loại. Nguyên tắc hoạt động của Soft voting là tính trung bình các xác suất dự đoán từ các mô hình thành phần để quyết định nhãn cuối cùng. Công thức tổng quát của phương pháp Soft voting được trình bày như sau:

$$P_{soft}(z = c|l) = \frac{1}{k} \sum_{i=1}^k P_i(z = c|l) \quad (1)$$

Trong đó:

- k : số lượng mô hình phân loại.
- $P_i(z = c|l)$: xác suất mô hình dự đoán mẫu l thuộc lớp c .

D. Độ đo đánh giá mô hình:

Chúng tôi sử dụng một số độ đo phổ biến trong học máy để đánh giá hiệu quả của mô hình phát hiện và phân loại ung thư trên nhũ ảnh. Những độ đo này bao gồm độ chính xác dựa trên tổng số ảnh thực nghiệm (Acc), độ nhạy, độ mất mát của mô hình trong quá trình huấn luyện. Các công thức được sử dụng trong bài báo bao gồm:

$$Acc = \frac{True.Pos + True.Nega}{True.Pos + True.Nega + Fal.Pos + Fal.Nega} \quad (2) \quad Precision = \frac{True.Pos}{True.Pos + Fal.Pos} \quad (3)$$


$$L(C, P) = - \sum_i C_i \log(P_i) \quad (4) \quad Recall = \frac{True.Pos}{True.Pos + Fal.Nega} \quad (5)$$

$$F1 - score = 2 \times \frac{Pre. \times Rec.}{Pre. + Rec.} \quad (6)$$

Trong đó: True.Pos: Số lượng mẫu lành tính được mô hình xác định đúng; True.Nega: Số lượng mẫu ác tính được mô hình xác định đúng; Fal.Pos: Số lượng mẫu lành tính được mô hình xác định nhầm là ác tính; Fal.Nega: Số lượng mẫu ác tính được mô hình xác định nhầm là lành tính. C_i : Nhãn đúng của lớp thứ i ; P_i : Xác suất lớp i của mô hình dự đoán.

III. MÔ HÌNH ĐỀ XUẤT

Hình 3 đề xuất phân loại ung thư trên nhũ ảnh dựa trên phương pháp tổ hợp mô hình học sâu được trình bày trong phần 2 bao gồm hai giai đoạn chính: (1) Huấn luyện mô hình – sử dụng các kỹ thuật tiền xử lý ảnh và phương pháp tăng cường dữ liệu để cải thiện khả năng học của mô hình, đồng thời tối ưu hóa kiến trúc mạng nơ-ron phù hợp với đặc điểm của nhũ ảnh; (2) Kiểm thử và đánh giá – triển khai mô hình trên tập dữ liệu thực nghiệm để đo lường độ chính xác, độ nhạy và độ đặc hiệu trong việc phát hiện và phân loại ung thư lành tính và ác tính.



Hình 3. Mô hình đề xuất ESD-NET phân loại ung thư trên nhũ ảnh

- Giai đoạn huấn luyện: Ở giai đoạn huấn luyện, dữ liệu đầu vào được tiền xử lý bằng một số kỹ thuật như cắt, tăng cường chất lượng ảnh và tăng cường dữ liệu (lật, xoay, phóng to ảnh,...). Tiếp theo, ảnh được đưa vào các mô hình máy học đề xuất để rút trích đặc trưng và huấn luyện. Tập dữ liệu được huấn luyện với 7 mô hình học sâu riêng biệt bao gồm: InceptionV3, ResNet152, ResNet50V2, DenseNet121, DenseNet201, VGG19 và Xception. Mỗi mô hình được huấn luyện độc lập trên cùng tập dữ liệu và tham số thống nhất. Chúng tôi sử dụng kỹ thuật dừng sớm (early stopping) trong quá trình huấn luyện để hạn chế mô hình gặp hiện tượng quá khớp dữ liệu (overfitting). Kết quả huấn luyện tốt nhất của mỗi mô hình được lưu lại phục vụ cho quá trình kiểm thử.
- Kiểm thử: ảnh kiểm thử được xử lý tương tự thông qua các bước tiền xử lý dữ liệu, trích đặc trưng sau đó áp dụng kỹ thuật Hard voting và Soft voting, nhằm đưa ra kết quả cuối cùng là lành tính hoặc ác tính.

Bảng 1. Kích bản và tham số huấn luyện mô hình

Kịch bản	Kiến trúc mạng	Kích thước (HxW)	Batch Size	Epochs	Optimizer	Learnig Rate
1	InceptionV3	384x192	32	100	Adam	1e-4
2	Resnet152	384x192	32	100	Adam	1e-4
3	Resnet50V2	384x192	32	100	Adam	1e-4
4	Densenet121	384x192	32	100	Adam	1e-4
5	Densenet201	384x192	32	100	Adam	1e-4
6	VGG19	384x192	32	100	Adam	1e-4
7	Xception	384x192	32	100	Adam	1e-4
8	ESD-NET – Hard voting					
9	ESD-NET – Soft voting					

IV. KẾT QUẢ THỰC NGHIỆM


1. Môi trường và tập dữ liệu cài đặt thực nghiệm

Môi trường cài đặt: Mô hình đề xuất được thực hiện trên nền tảng Kaggle, một số thư viện trên Tensorflow và Keras hỗ trợ đào tạo mô hình. Bộ vi xử lý Xeon® 2.00 GHz, RAM 30GB và với chip đồ họa sử dụng Nvidia Tesla P100 (RAM 16GB).

Tập dữ liệu: Các ảnh trong bộ dữ liệu được thu thập từ dữ liệu công khai VinDr[15] và dữ liệu của một số bệnh viện tại Thành phố Cần Thơ, dữ liệu sau đó được kiểm tra bởi các bác sĩ chuyên khoa trước khi đưa vào quá trình huấn luyện và kiểm thử. Để đánh giá quá trình phân loại trên các thuật toán chúng tôi thực hiện chia tập dữ liệu thành 3 loại: huấn luyện gồm 2,841 ảnh, tập xác thực gồm 355 ảnh và tập kiểm thử gồm 1,068 ảnh tương ứng với 2 nhóm lành tính (Benign) và ác tính (Malignant).


2. Kết quả huấn luyện

a) Kết quả độ đo Acc và Loss của các kịch bản huấn luyện




Hình 4. Kết quả độ đo Acc và Loss của các kịch bản

Dựa trên biểu đồ Hình 4 cho thấy độ đo Acc và Loss qua các epoch của 7 kịch bản đều có xu hướng tăng dần độ chính xác và giảm Loss ổn định qua mỗi epoch. Hầu hết các kịch bản cho kết quả Acc cao và độ Loss thấp, cho thấy quá trình huấn luyện hiệu quả và mô hình học tốt trên dữ liệu đầu vào. Kịch bản 3 có hiện tượng dao động và chênh lệch giữa training và validation dẫn đến hiệu suất đầu ra thấp.



Hình 5. Biểu đồ cột đánh giá Accuracy các kịch bản




Hình 6. Biểu đồ cột đánh giá Loss các kịch bản

Biểu đồ Hình 5, 6 cho thấy hiệu suất phân loại của từng mô hình trên tập dữ liệu kiểm thử. Trong đó, kịch bản 1 đạt Accuracy cao nhất với 96.5%, theo sau là kịch bản 4 95.6% và kịch bản 5 95.1%. Các mô hình này cho thấy khả năng học tốt các đặc trưng phân biệt giữa u lành và u ác từ nhũ ảnh, giúp đưa ra quyết định phân loại chính xác hơn.

Khi tiến hành so sánh tại giá trị loss thì kịch bản 4 đạt loss thấp nhất 0.184, kịch bản 5 có độ mất mát thông tin là 0.190 và kịch bản 1 là 0.196. Trong khi đó, kịch bản 3 lại có loss cao vượt trội 0.387 điều này phản ánh đúng quá trình huấn luyện khi kịch bản này có độ ổn định thấp trên Acc và Loss.


b) Thời gian huấn luyện của các kịch bản



Hình 7. Biểu đồ cột đánh giá thời gian huấn luyện các mô hình

Trong Hình 7 trình bày thời gian huấn luyện được tổng hợp cho thấy sự khác biệt đáng kể giữa các mô hình học sâu. Trong đó, DenseNet201 là mô hình mất nhiều thời gian huấn luyện nhất với 156.52 phút, tiếp theo là VGG19 với 136.75 phút và ResNet152 với 81.63 phút. Điều này phản ánh rõ mối liên hệ giữa độ sâu mạng, mức độ phức tạp của kiến trúc và chi phí tính toán trong quá trình huấn luyện. Ngược lại, các mô hình như ResNet50V2 (52.27 phút) và DenseNet121 (67.38 phút) có thời gian huấn luyện ngắn hơn đáng kể, nhờ kiến trúc gọn nhẹ và tối ưu hơn. Kết quả này cho thấy, trong những ứng dụng yêu cầu triển khai thực tế hoặc tài nguyên hạn chế, các mô hình có thời gian huấn luyện ngắn có thể là lựa chọn phù hợp. Nhìn chung, phân tích thời gian huấn luyện đóng vai trò quan trọng trong việc cân nhắc lựa chọn mô hình, đảm bảo sự hài hòa giữa hiệu quả phân loại và chi phí tính toán khi áp dụng vào thực tế.

c) Ma trận nhầm lẫn trên dữ liệu kiểm thử




Hình 8. Ma trận nhầm lẫn trên các kịch bản huấn luyện

Qua phân tích ma trận nhầm lẫn của từng kịch bản, có thể nhận thấy phần lớn mô hình đều đạt tỷ lệ phân loại đúng cao ở cả hai lớp. Kịch bản 2 cho thấy mô hình ResNet152 nổi bật khi phân loại chính xác tới 471 mẫu Benign và 550 mẫu Malignant, với tỷ lệ nhầm lẫn rất thấp, chỉ 30 mẫu Benign và 17 mẫu Malignant. Kịch bản 1, 3 và 4 cũng thể hiện hiệu quả tốt, với số mẫu nhầm lẫn dao động từ 20 – 40, phản ánh khả năng học đặc trưng ổn định. Ngược lại, kịch bản 5, mô hình DenseNet201 thể hiện rõ nhược điểm với số lượng nhầm lẫn cao nhất (102 mẫu Benign và 57 mẫu Malignant), cho thấy kiến trúc này gặp khó khăn trong việc phân biệt rõ ràng giữa hai nhóm trên tập dữ liệu nghiên cứu. Xception và VGG19 của kịch bản 6 và 7 giữ hiệu suất phân loại trung bình; tuy Xception có số nhầm lẫn ở lớp Benign cao (59 mẫu), nhưng vẫn phân loại đúng phần lớn mẫu Malignant, trong khi VGG19 có mức nhầm lẫn cân bằng hơn giữa hai lớp.

d) Kết quả tổ hợp mô hình học sâu

Trên kết quả đầu ra của các mô hình học sâu chúng tôi tiến hành tổ hợp bằng phương pháp Hard voting và Soft voting. Kết quả tổ hợp được đánh giá dựa trên độ chính xác và khả năng phân biệt giữa hai lớp u lành tính (benign) và u ác tính (malignant) thông qua ma trận nhầm lẫn được trình bày như sau:



Hình 9. Ma trận nhầm lẫn khi áp dụng ESD-NET trên kịch bản 8 và 9

Kết quả Hình 9 cho thấy cả hai phương pháp tổ hợp đều cho kết quả dự đoán tốt với độ chính xác cao, trong đó kịch bản 9 cho thấy hiệu suất cao hơn so với kịch bản 8. Cụ thể, kịch bản 8 dự đoán đúng 475 mẫu benign và 549 mẫu malignant, trong khi kịch bản 9 lần lượt là 474 và 547. Đồng thời, số lượng mẫu malignant bị nhầm giảm từ 20 xuống còn 18, cho thấy kịch bản 9 có độ nhạy cao hơn với các trường hợp phân loại ác tính – điều đặc biệt quan trọng trong bài toán hỗ trợ chẩn đoán sớm ung thư.









e) Đánh giá hiệu suất phân loại

Bảng 2. Kết quả phân loại lớp B (Benign - lành tính) và M (Malignant - ác tính) trên tập dữ liệu kiểm tra

Kịch bản	Phân loại	Precision (%)	Recall (%)	F1- score (%)	Accuracy (%)
1	B	94.6	94.6	92.0	94.7
	M	94.2	94.9	91.0	
2	B	96.5	94.0	95.3	95.6
	M	94.8	97.0	95.9	
3	B	94.3	95.4	94.8	95.1
	M	95.9	94.9	95.4	
4	B	95.3	92.0	93.6	94.1
	M	93.2	95.9	94.5	
5	B	87.5	79.6	83.4	85.1
	M	83.3	90.0	86.5	
6	B	90.2	93.8	92.0	92.3
	M	94.3	91.0	92.6	
7	B	92.5	88.2	90.3	91.1
	M	90.0	93.7	91.8	
8	B	95.9	94.6	95.2	95.6
	M	95.3	96.4	95.8	
9	B	96.3	94.8	95.5	95.8
	M	95.4	96.8	96.1	

Dựa trên kết quả phân loại của các kịch bản thực nghiệm cho thấy phương pháp tổ hợp mô hình học sâu cải thiện rõ rệt về các chỉ số đánh giá hiệu suất phân loại như Precision, Recall, F1-score và Accuracy. Cụ thể, các mô hình trong các kịch bản từ 1 đến 9 đều đạt được độ chính xác (Accuracy) khá cao, dao động từ 85.1% đến 95.8%. Trong đó, kịch bản 9 đạt độ chính xác cao nhất với 95.8%, đồng thời cũng có các chỉ số Precision và Recall đều trên 95% cho cả hai nhóm B (lành tính) và M (ác tính), cho thấy tính ổn định trong việc phân loại. Thông qua các chỉ số Precision, Recall và F1-score phản ánh sự ảnh hưởng của từng mô hình tổ hợp được sử dụng đồng thời cho thấy vai trò quan trọng của việc lựa chọn và kết hợp các mô hình học sâu phù hợp trong từng tình huống cụ thể để đạt được hiệu quả phân loại tối ưu trong chẩn đoán ung thư vú.

f) Kết quả kiểm thử

Phương pháp	Ảnh kết quả			
	Ảnh 1	Ảnh 2	Ảnh 3	Ảnh 4
Hard voting				
	Nhân gốc: Benign Dự đoán: Benign Voting: 0/7 Malignant 7/7 Benign	Nhân gốc: Benign Dự đoán: Benign Voting: 0/7 Malignant 7/7 Benign	Nhân gốc: Malignant Dự đoán: Malignant Voting: 7/7 Malignant 0/7 Benign	Nhân gốc: Malignant Dự đoán: Malignant Voting: 7/7 Malignant 0/7 Benign
Soft voting				
	Nhân gốc: Benign Dự đoán: Benign P_soft(z=0): 1.00 P_soft(z=1): 0.00	Nhân gốc: Benign Dự đoán: Benign P_soft(z=0): 0.99 P_soft(z=1): 0.01	Nhân gốc: Malignant Dự đoán: Malignant P_soft(z=0): 0.00 P_soft(z=1): 1.00	Nhân gốc: Malignant Dự đoán: Malignant P_soft(z=0): 0.01 P_soft(z=1): 0.99

Phương pháp Hard voting cho thấy hiệu quả trong các trường hợp có sự đồng thuận cao giữa các mô hình. Tuy nhiên, đối với các ảnh khó, nơi mà một số mô hình dự đoán sai, phương pháp này dễ bị sai lệch nếu mô hình sai chiếm đa số. Điều này cho thấy một hạn chế của phương pháp Hard voting là không xét đến độ tin cậy (xác suất) của từng mô hình, mà chỉ đơn thuần dựa vào số phiếu. Trong khi đó, phương pháp Soft voting cho thấy hiệu quả hơn nhờ việc kết hợp xác suất từ nhiều mô hình giúp làm giảm ảnh hưởng của các dự đoán lệch pha từ từng mô hình riêng lẻ, từ đó nâng cao độ ổn định của kết quả phân loại.

V. KẾT LUẬN

Trong bài báo này, chúng tôi đã đề xuất mô hình ESD-NET nhằm nâng cao hiệu quả phân loại ung thư vú trên nhũ ảnh thông qua việc tổ hợp các mô hình học sâu. Cụ thể, đầu ra của các mô hình được kết hợp bằng hai chiến lược tổ hợp là Hard voting và Soft voting. Kết quả thực nghiệm cho thấy mô hình đề xuất vượt trội so với các mô hình đơn lẻ về hiệu suất phân loại. Trong đó, Soft voting đạt độ chính xác cao nhất với 95.8%, nhỉnh hơn so với Hard voting (95.6%), đồng thời cho kết quả F1-score và Recall tốt hơn ở cả hai lớp lành tính và ác tính. Hiệu quả cao của Soft voting có thể lý giải nhờ khả năng khai thác toàn diện các thông tin xác suất từ nhiều mô hình học sâu, giúp giảm thiểu sai số ngẫu nhiên và tăng cường độ ổn định trong dự đoán. Đặc biệt, mô hình thể hiện ưu thế rõ rệt trong việc phát hiện các trường hợp ung thư ác tính – yếu tố then chốt trong hỗ trợ chẩn đoán sớm và điều trị kịp thời. Bên cạnh đó, sự khác biệt về hiệu quả giữa các kịch bản tổ hợp cho thấy kết quả phân loại còn phụ thuộc vào đặc điểm của từng mô hình thành phần cũng như dữ liệu đầu vào. Điều này mở ra hướng nghiên cứu tiếp theo nhằm tối ưu hóa việc lựa chọn mô hình nền và chiến lược tổ hợp phù hợp cho từng tình huống cụ thể. Trong thời gian tới, chúng tôi tiếp tục mở rộng hướng tiếp cận này sang bài toán phân đoạn khối u trên nhũ ảnh, tiến tới xây dựng một hệ thống hỗ trợ chẩn đoán toàn diện, kết hợp cả phát hiện và phân loại nhằm nâng cao hiệu quả trong tầm soát và điều trị ung thư vú.

VI. TÀI LIỆU THAM KHẢO

[1] B. S. Chhikara and K. Parang, “Global Cancer Statistics 2022: the trends projection analysis,” 2023.

[2] Y. Eroğlu, M. Yildirim, and A. Çinar, “Convolutional Neural Networks based classification of breast ultrasonography images by hybrid method with respect to benign, malignant, and normal using mRMR,” *Computers in biology and medicine*, vol. 133, p. 104407, 2021.

[3] A. P. Adedigba, S. A. Adeshina, and A. M. Aibinu, “Performance Evaluation of Deep Learning Models on Mammogram Classification Using Small Dataset. *Bioengineering* 2022, 9, 161.” s Note: MDPI stays neutral with regard to jurisdictional claims in published ..., 2022. Accessed: June 10, 2025. [Online]. Available: <https://www.academia.edu/download/91821754/pdf.pdf>

[4] M. S. Hashim and A. A. Yassin, “Breast Cancer Prediction Using Soft voting Classifier Based on Machine Learning Models.,” *IAENG International Journal of Computer Science*, vol. 50, no. 2, 2023, Accessed: June 09, 2025. [Online]. Available: <https://www.researchgate.net/profile/Mohammed-S->

- Hashim/publication/373020233_Breast_Cancer_Prediction_Using_Soft_Voting_Classifier_Based_on_Machine_Learning_Models/links/64d4c2e1b684851d3d9d2ae1/Breast-Cancer-Prediction-Using-Soft-Voting-Classifier-Based-on-Machine-Learning-Models.pdf
- [5] T. M. Hanis, M. A. Islam, and K. I. Musa, “Diagnostic accuracy of machine learning models on mammography in breast cancer classification: a meta-analysis,” *Diagnostics*, vol. 12, no. 7, p. 1643, 2022.
 - [6] C. Szegedy, V. Vanhoucke, S. Ioffe, J. Shlens, and Z. Wojna, “Rethinking the inception architecture for computer vision,” presented at the Proceedings of the IEEE conference on computer vision and pattern recognition, 2016, pp. 2818–2826.
 - [7] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” presented at the Proceedings of the IEEE conference on computer vision and pattern recognition, 2016, pp. 770–778.
 - [8] C. Szegedy, S. Ioffe, V. Vanhoucke, and A. Alemi, “Inception-v4, inception-resnet and the impact of residual connections on learning,” in *Proceedings of the AAAI conference on artificial intelligence*, 2017. Accessed: June 09, 2025. [Online]. Available: <https://ojs.aaai.org/index.php/aaai/article/view/11231>
 - [9] G. Huang, Z. Liu, L. Van Der Maaten, and K. Q. Weinberger, “Densely connected convolutional networks,” in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2017, pp. 4700–4708. Accessed: June 09, 2025. [Online]. Available: http://openaccess.thecvf.com/content_cvpr_2017/html/Huang_Densely_Connected_Convolutional_CVPR_2017_paper.html
 - [10] G. Huang, Z. Liu, G. Pleiss, L. Van Der Maaten, and K. Q. Weinberger, “Convolutional networks with dense connectivity,” *IEEE transactions on pattern analysis and machine intelligence*, vol. 44, no. 12, pp. 8704–8716, 2019.
 - [11] K. Simonyan and A. Zisserman, “Very deep convolutional networks for large-scale image recognition,” *arXiv preprint arXiv:1409.1556*, 2014.
 - [12] F. Chollet, “Xception: Deep learning with depthwise separable convolutions,” in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2017, pp. 1251–1258. Accessed: June 09, 2025. [Online]. Available: http://openaccess.thecvf.com/content_cvpr_2017/html/Chollet_Xception_Deep_Learning_CVPR_2017_paper.html
 - [13] T. G. Dietterich, “Ensemble Methods in Machine Learning,” in *Multiple Classifier Systems*, vol. 1857, in Lecture Notes in Computer Science, vol. 1857. , Berlin, Heidelberg: Springer Berlin Heidelberg, 2000, pp. 1–15. doi: 10.1007/3-540-45014-9_1.
 - [14] T. Hastie, R. Tibshirani, and J. Friedman, “The elements of statistical learning.” Citeseer, 2009. Accessed: June 12, 2025. [Online]. Available: <https://citeseerx.ist.psu.edu/document?repid=rep1&type=pdf&doi=8ebe6ba41d8a32ad977fdd2aed5e70f61831bcb3>
 - [15] H. H. Pham, H. N. Trung, and H. Q. Nguyen, “Vindr-mammo: A large-scale benchmark dataset for computer-aided detection and diagnosis in full-field digital mammography,” *Sci Data*, 2022, Accessed: June 09, 2025. [Online]. Available: <https://www.physionet.org/content/vindr-mammo/1.0.0/>

DEEP LEARNING ENSEMBLE WITH ESD-NET IN BREAST CANCER CLASSIFICATION ON MAMMOGRAM

Ho Dat Tran, Thuong Cang Phan, Vinh Phong Nguyen, Anh Cang Phan

ABSTRACT— The early identification and treatment of cancer are crucial for enhancing the patient's capacity for recovery. Historically, deep learning models have significantly aided the medical industry, enhancing physicians' capacity to diagnose and treat illnesses. Nevertheless, the outcomes from each individual model are frequently unstable and susceptible to the properties of the input data, hence influencing the classification process of machine learning models. This paper introduces a novel network model, ESD-NET, which integrates seven existing models: InceptionV3, ResNet152, ResNet50V2, DenseNet121, DenseNet201, VGG19, and Xception, for the detection and classification of cancer in mammograms. The preliminary data undergoes preprocessing to eliminate noise, standardize, and enhance image quality before to training. Based on the training outcomes of the models, we perform an ensemble of deep learning models utilizing voting procedures to leverage the strengths of individual models. The suggested method enhances classification performance by Soft voting strategies, attaining 95.8% accuracy and 95.6% accuracy with Hard voting on the test set. The study's results enhance the reliability of the proposed model for early breast cancer identification.